

Compte Rendu

# Projet de Machine Learning

Classifieur de musiques selon leur genre musical

---

CABRERA Cyril

LOK Tshanon

Mars 2021

## Objectifs du projet

Le but de ce projet est de créer un modèle d'Apprentissage Automatique permettant la classification de musiques selon leur genre musical (rock, pop, RnB, etc...).

L'idée est de pouvoir créer un modèle supervisé permettant la classification de plusieurs classes (les genres musicaux). Plusieurs algorithmes vus en cours peuvent être utilisés pour modéliser ce problème : le SVM et le bayésien par exemple. Nous avons décidé d'utiliser le SVM.

## Pré-Processing

### Choix des données

Afin de pouvoir réaliser cela, nous avons utilisé une base de données que l'on peut trouver à l'adresse suivante :

<https://www.kaggle.com/zaheenhamidani/ultimate-spotify-tracks-db?select=SpotifyFeatures.csv>

### Décisions sur les données

Certains choix ont été pris lors de la création du modèle pour améliorer les performances de calculs et la précision des résultats obtenus.

Tout d'abord nous nous sommes intéressés à la fréquence d'apparition des différents genres dans notre dataset. Comme on peut le voir dans la figure 1, le genre "A Capella" est sous-représenté dans le data-set (199 contre au moins 5000 pour le second genre le moins représenté). De même pour "Children's Music".




Figure 1: Nombre d'occurrence en fonction des genres musicaux

Nous nous sommes intéressés par la suite aux genres musicaux en eux-même. Certaines classes ne semblaient pas être des genres ou bien ne semblaient pas être très distinctes des autres. Pour visualiser un peu mieux les différentes classes, on a essayé de les exprimer en fonction de leur deux premiers PCA et de les afficher. Le but était de voir si les classes étaient bien toutes distinctes ou bien s'il y avait des ressemblances. Voilà nos résultats (chaque couleur représente une classe) :




Figure 2 : Représentation des différentes classes exprimées en fonction de leur PCA

Certaines classes sont “superposées” sur d’autres. Il nous semble donc assez compliqué d’établir un modèle permettant une classification avec un taux de réussite très élevé.

On remarque tout de même que certains genres se distinguent (amas violet et vert). On s’y est intéressé et voici nos résultats :

	Features	Horizontalement		Features	Verticalement
0	acousticness	0.798237	8	speechiness	0.844829
4	instrumentalness	0.615215	5	liveness	0.821810
2	duration_ms	0.125105	0	acousticness	0.231864
5	liveness	-0.048906	3	energy	0.150273
8	speechiness	-0.054342	10	valence	0.077690
9	tempo	-0.300246	1	danceability	0.056382
7	popularity	-0.466390	2	duration_ms	-0.018908
10	valence	-0.630597	6	loudness	-0.019800
1	danceability	-0.652403	9	tempo	-0.189256
3	energy	-0.845294	4	instrumentalness	-0.235946
6	loudness	-0.886828	7	popularity	-0.400861

Figure 3 : Corrélations

Majoritairement, les genres se distinguent grâce à leur speechiness et popularity (violet et vert).

Comme certains genres se ressemblent, nous avons donc décidé pour la suite du projet de ne pas en prendre en compte certains. “World”, “Anime”, “Movie”, “Soundtrack”, “Alternative”, “Indie”, “Children’s Music” ne seront pas pris en compte. En effet, “World” est un amalgame de plusieurs genres musicaux qui viennent de divers pays du monde sans réellement les associer à un vrai

genre musical et “Anime”, “Movie”, “Alternative”, “Indie” et “Soundtrack” sont variés dans les styles (on peut avoir du rock, de la musique classique, des musiques de films d’action, de films pour enfants ou historiques, etc... par exemple on trouve le thème principal de Batman et les musiques de Nemo). Cela aurait pu donc fausser nos résultats étant donné la similarité avec les genres musicaux déjà présents avec lesquels ils ne sont pas associés. On pourrait, en guise d’ouverture à ce projet, faire du clustering pour classer ces musiques dans les genres musicaux conservés avec notre modèle.

Enfin, d’autres genres musicaux ont été enlevés : on aurait pu les regrouper avec les autres styles (ce qui ne semble pas irraisonnable puisque les genres se confondent sur notre graph [fig.2]) mais deux raisons nous empêchent de le faire. Nous ne sommes pas des experts pour rassembler deux “genres” ensemble et les rassembler pourrait engendrer une dispersion d’un genre musical. Nous avons donc au final 10 styles musicaux qui sont distribués de la manière suivante :




Figure 4 : Données après avoir enlevé des classes

Les données obtenues sont meilleures que précédemment mais il semble tout de même compliqué de bien classer puisque l’on a encore des “superpositions” de genres.

## Modélisation + Optimisation

Initialement, notre but était de faire une SVM pour pouvoir classer les musiques en fonction de leur genre. Cependant, en faisant quelques manipulations des données, on s’est rendu compte que ça prenait beaucoup de temps donc en plus de la SVM, on a opté pour faire une PCA.

On a cherché à calculer les paramètres les plus optimaux pour utiliser une SVM et une PCA à l’aide de la partie 3 du TP3. Cette manipulation prenait également beaucoup de temps de calcul sur nos machines (+30 minutes). On a donc opté pour déterminer à la main le nombre de dimensions optimales (n\_components).

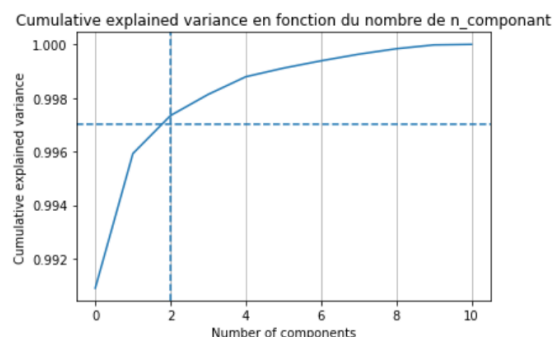


Figure 5

On essaie de déterminer graphiquement le nombre de dimensions optimales pour la PCA. Pour 0.997 de variance expliquée, on peut prendre  $n\_components = 2$ .

Une fois le  $n\_components$  obtenu, nous avons cherché à déterminer la valeur optimale pour la variable  $C$ , variable correspondant à un paramètre de régularisation utilisé par la suite dans `sklearn.svm.SVC`. Pour la déterminer, nous avons décidé de varier  $C$  entre  $10^{-3}$  à  $10^2$  et faire de la Cross Validation afin d'obtenir un  $C$  assez robuste.

On suppose que  $C \in [10^{-1}; 10^1]$  semble acceptable. Pour une question de vitesse de calculs, on prendra pour la suite  $C = 1$ .

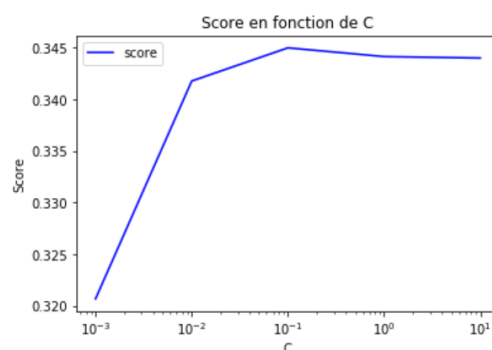


Figure 6

En prenant en compte ces paramètres, nous obtenons :

**BALANCED test score: 0.3326433517373067**




Figure 7: Score

Nous avons donc un score de 33%. Cela ne nous étonne pas non plus puisque d'après notre travail pendant le préprocessing, les musiques se distinguaient assez peu.

En position 0 et 9, la musique classique et comédie sont assez bien reconnues par notre modèle. Le reste semble peu reconnaissable.

## Modélisation 2 : avec uniquement 3 genres musicaux

Motivation :

On a voulu voir comment fonctionne notre modèle avec uniquement trois genres musicaux. Nous avons donc sélectionné 3 genres : “Classical” , “Rock” et “Comedy”.




Figure 8 : PCA, matrice de confusion avec trois classes

Les 3 genres sont plus distinguables que précédemment. On pense donc avoir un meilleur score.

En faisant les mêmes manipulations qu’avant, voici nos résultats.

**BALANCED test score: 0.9161781451674802**



## Conclusion

Le but du projet était de créer un modèle de Machine Learning permettant la classification de musiques en fonction de leur genre musical. Le pré-processing nous a permis de visualiser les données en prenant en compte leur deux premiers Principal component analysis (PCA). On en a déduit qu'il serait difficile de classer les musiques si on prenait en compte tous les genres puisque ces derniers ne se distinguent pas beaucoup.

Comme nous l'avions imaginé, la classification en fonction du genre musical n'a pas été un grand succès : on a un score d'à peu près 33% donc pas satisfaisant pour utiliser le modèle par la suite.

En prenant en compte uniquement 3 genres facilement distinguables à nos yeux, nous avons réussi à obtenir un score de 91%.

Obtenir ce score nous est possible en réduisant le nombre de classes mais il est possible que l'on puisse prédire un genre musical à l'aide d'autres algorithmes comme un `decision_tree`.

Même si nous n'avons pas réussi à bien classer, le projet nous a beaucoup plus :)